

Apprentissage de motifs
spatio-temporels dans un
réseau de neurones
impulsionnels

Table des matières

I.	Introduction	4
	L'apprentissage automatique	4
	Temporalité de l'information	6
	Objectif de mon stage	9
	Etat de l'art	10
II.	Méthode	11
	Génération de l'activité – motifs structurés dans du bruit	11
	<i>Génération du motif spatio-temporel.....</i>	<i>11</i>
	<i>Génération de l'activité de bruit.....</i>	<i>12</i>
	Modélisation des neurones de sortie – delayed Leaky Integrate and Fire neurons (LIF)	14
	<i>Modélisation de la transmission de l'information</i>	<i>14</i>
	<i>Modélisation de l'intégration de l'information</i>	<i>15</i>
	<i>Modélisation de la détection du motif</i>	<i>17</i>
	Règle d'apprentissage : STDP supervisée	18
	<i>Apprentissage supervisé pour la détection d'un seul motif spatio-temporel.....</i>	<i>19</i>
	<i>Apprentissage supervisé pour la détection de plusieurs motifs spatio-temporels</i>	<i>24</i>
	<i>Apprentissage non supervisé pour la détection d'un motif spatio-temporel</i>	<i>24</i>
III.	Résultats.....	25
	Expérience 1 : apprentissage supervisé d'un motif unique.....	25
	Expérience 2 : apprentissage supervisé de plusieurs motifs	28

Expérience 3 : apprentissage non-supervisé de plusieurs motifs	35
IV. Discussion & perspectives.....	36

I. Introduction

Les neurosciences computationnelles sont un champ d'étude à l'interface entre les neurosciences, les mathématiques et l'intelligence artificielle. Nées de l'émergence de la théorie computationnelle de l'esprit, dans laquelle l'esprit lui-même y est considéré comme un système informatique, les neurosciences computationnelles décrivent le système nerveux à l'aide de modèles mathématiques et informatiquesⁱ. La visée de ce domaine de recherche est aussi bien de contribuer aux recherches de neurosciences théoriques et fondamentales que de favoriser le développement de l'intelligence artificielle, en s'inspirant de l'organisation fonctionnelle du système nerveux pour concevoir des systèmes informatiques intelligents. Les neurosciences computationnelles représentent alors un échange constant entre ces disciplines intimement liées.

L'apprentissage automatique

L'apprentissage automatique, ou '*machine learning*' en anglais, est un exemple pertinent de la collaboration de ces deux domaines. L'objectif est de réaliser des algorithmes qui, à l'image du système nerveux, seraient capable d'apprendre et d'améliorer leurs performances à résoudre une tâche spécifique, en déterminant de façon autonome les caractéristiques d'intérêt à extraire des données, sans que l'utilisateur n'ait eu à les définir explicitement. Pour cela, l'algorithme est agencé sous la forme d'un réseau de neurones d'une ou plusieurs couches interconnectées par des modèles de connections synaptiques dont la force est représentée par un poids. Le rôle du réseau est d'établir des prédictions à partir de l'analyse des données par un processus d'optimisation. Cela comporte généralement deux phases, la première est la phase dite d'apprentissage, ou d'entraînement. Elle est réalisée préalablement à la phase d'utilisation pratique du modèle. Il existe plusieurs stratégies visant à entraîner le

modèle. Si l'on connaît l'étiquette des données que l'on utilise pour l'entraînement, c'est à dire la prédiction correcte à effectuer, on entraînera le modèle de façon supervisée : suite à la présentation de chaque donnée, le réseau réalise une prédiction d'appartenance à une classe, si la prédiction est fausse, le réseau réajustera la force de ses connexions synaptiques pour établir une prédiction qui se rapproche le plus de la classification correcte/à effectuer. Si l'on ne connaît pas l'étiquette des données, on optera pour un modèle de *clustering* suivant une stratégie d'apprentissage non supervisée. Dans ce cas, l'algorithme doit déterminer par lui-même les structures sous-jacentes à ces données pour les rassembler en groupe homogènes. De la même manière que pour la stratégie d'apprentissage supervisée, le réseau modulera ses poids de connexions synaptiques au cours de l'apprentissage, dans le but d'analyser et traiter les données de la manière la plus optimale possible. Il existe également une stratégie d'apprentissage semi-supervisée où les données sont étiquetées de façon partielle. Cela permet de favoriser l'apprentissage et de le rendre moins imprévisible. En effet, bien que l'apprentissage non supervisé permette de réaliser des tâches plus complexes que l'apprentissage supervisé, il se peut que le réseau ne détermine pas le bon nombre de classe ou rassemble les données selon des structures non pertinentes. L'apprentissage semi-supervisé représente alors un bon intermédiaire entre ces deux stratégies.

	detect on	SL	UL	SSL
x	☺	☺	☺	☺
p	☺	?	?	?
y	?	☺	?	in part

identity but
not like

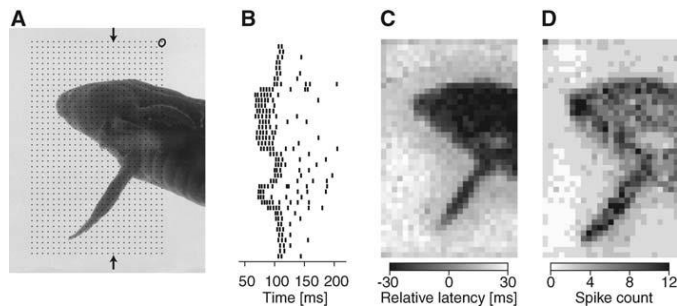
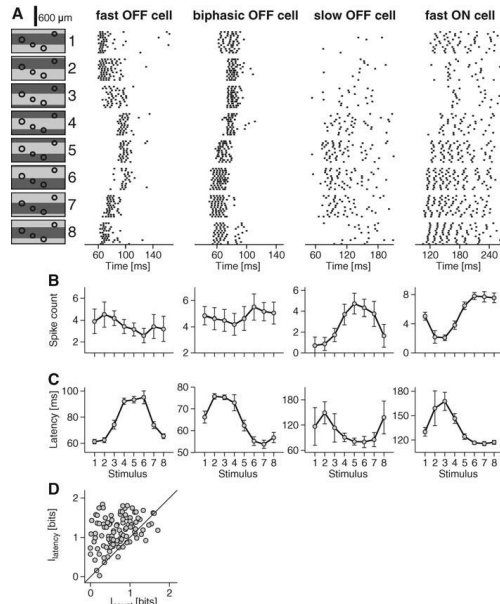
L'apprentissage automatique s'inspire ainsi de l'une des composantes essentielles du fonctionnement du système nerveux : la plasticité des poids de connexion synaptique. En effet, à l'origine de l'apprentissage, de l'encodage et de la transmission de l'information, les poids synaptiques modulent l'amplitude des réponses post-synaptiques induites par la libération de neurotransmetteurs au niveau de la synapse. La distribution des poids dans le réseau impacte alors aussi bien l'encodage en amplitude et en fréquence de l'information que sa transmission au sein du réseau : un poids synaptique élevé permettrait la transmission de l'information dans une branche spécifique du réseau, alors qu'un poids synaptique faible, ou un poids synaptique élevé sur une synapse inhibitrice, stopperait la propagation de l'activité dans cette branche. La matrice de poids synaptiques d'un réseau permettrait alors d'associer des entrées à des sorties spécifiques et la plasticité de ces derniers permettrait quant-à-elle, d'apprendre les associations et les réponses les plus adaptées.

Commenté [BC1]: à tej ?

Temporalité de l'information

Cependant, le système nerveux n'utilise pas que le codage en fréquence et en amplitude pour encoder, traiter et transmettre l'information, mais également une composante encore bien trop ignorée par le champ de l'apprentissage automatique : la temporalité de l'information.

L'importance de cette temporalité dans l'encodage de l'information visuelle a notamment été mise en évidence par les travaux de Gollisch et Meisterⁱⁱ et de Celebrini et Thorpeⁱⁱⁱ. Par des enregistrements neurophysiologiques, ces deux équipes démontrent que l'information spatiale d'un stimulus visuel ne serait pas encodée, comme on a tendance à le croire, par la fréquence de décharge des cellules ganglionnaires de la rétine ou des neurones corticaux des aires visuelles primaires, mais par la latence de décharge du premier potentiel d'action.

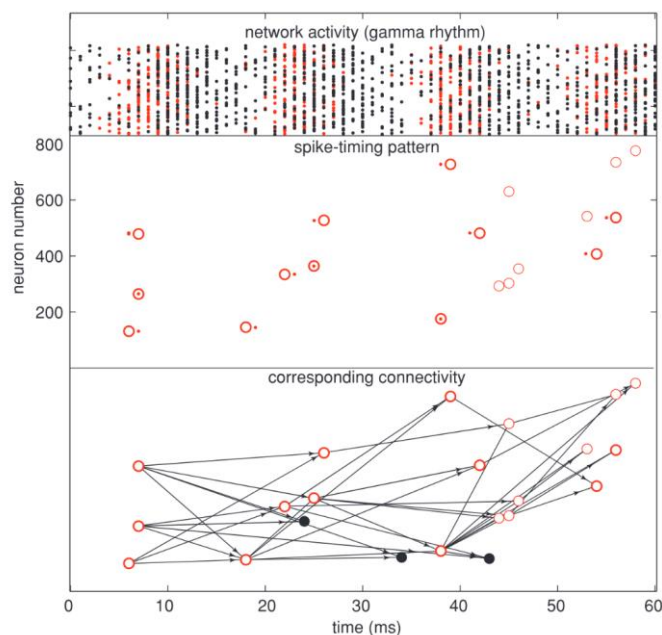


La temporalité n'est pas seulement mise à profit lors de l'encodage de l'information, elle est aussi extrêmement importante lors de la transmission de l'information. Relativement à cela, il est opportun d'aborder la théorie des *chaînes de synchronicité* (*synfire chains* en Anglais) de Moshe Abeles, énoncée en 1991 exposée dans son livre *Corticonics*^{iv}. Il y demande si le rôle des neurones corticaux serait *d'intégrer* des entrées synaptiques, ou plutôt de *détecter des coïncidences temporelles* dans les patrons d'activité. Bien que la première hypothèse favorise la théorie du codage en fréquence, la seconde possibilité met en évidence la nécessité d'une précision temporelle dans le code neuronal. Selon Moshe Abeles, cette précision temporelle

serait assurée par la sensibilité des neurones corticaux aux excitations simultanées, permettant de resynchroniser les volées de potentiels d'action asynchrones à chaque nœud, en prenant la forme de chaînes de synchronicité. Depuis, de nombreuses études ont démontré l'émergence de la synchronicité dans l'activité de populations de neurones^v.

La réponse d'un neurone biologique dépendant largement de la séquence temporelle précise à laquelle les potentiels d'actions présynaptiques rejoignent l'arbre dendritique, les délais axonaux sont également une composante essentielle à prendre en compte lorsque l'on aborde la question de la temporalité dans le système nerveux. C'est ainsi que E. Izhichevitch abordera la notion de groupes polychrones dans ses travaux et participera à valider la théorie des chaînes de synchronicité d'Abeles^{vi}. Il propose que si l'on ne considère que le nombre de potentiels d'action nécessaires pour dépasser un seuil de voltage, les signaux asynchrones sont moins efficaces que les signaux synchrones. Cependant, si l'on prend aussi en compte le temps de propagation entre deux neurones, les signaux synchrones peuvent ne pas coïncider significativement au niveau du neurone post-synaptique, contrairement aux signaux asynchrones/polychrones. Pour démontrer cette hypothèse, il construit un réseau caractérisé par des délais de conduction fixes et par une règle d'apprentissage des poids en fonction du moment d'occurrence des potentiels d'action pré et post synaptique : la *Spike Timing Dependant Plasticity* (STDP). En raison de l'interaction entre les délais de conduction et la STDP, les neurones s'organisent spontanément en groupes et génèrent des modèles d'activités polychrones stéréotypées, c'est-à-dire qu'ils présentent des motifs de décharge répétés mais non synchrones (Figure x). Les neurones composant un groupe déchargent à des moments différents, mais en raison des délais, les potentiels d'actions atteignent l'extrémité synaptique au même moment. Cette synchronie conduit à la sommation des potentiels post-synaptiques excitateurs et donc, au franchissement du seuil de voltage et à la décharge d'un potentiel d'action. Selon la règle de STDP, les neurones impliqués dans cette activité verront leur poids de connexion augmenter et constitueront ainsi un groupe polychrone. Il est intéressant de noter

que, grâce au fait que les neurones peuvent être impliqués dans différents groupes polychrones, le nombre de groupes coexistant dépasse largement le nombre de neurones du réseau, traduisant ainsi, une capacité de mémoire sans précédent du système.



Ensemble, ces résultats démontrent l'intérêt de la dimension temporelle dans le traitement de l'information nerveuse : une capacité d'encodage exacerbée, une transmission de l'information raffinée et, **par le caractère plastique des délais de conduction,** une capacité d'apprentissage amplifiée.

Objectif de mon stage

L'objectif de mon stage aura alors été de tirer parti de cette dimension temporelle pour améliorer les performances des réseaux d'apprentissages actuels. L'encodage, le traitement, la transmission de l'information ainsi que l'apprentissage seront réalisées en prenant en compte cette dimension et bénéficieront ainsi d'une puissance de calcul supplémentaire. Nous avons entraîné nos réseaux pour qu'ils reconnaissent, dans des raster plot reproduisant

Commenté [BC2]: rajouter un article là dessus ?

Commenté [GU3R2]: par exemple
10.1523/jneurosci.3185-16.2017

l'activité neuronale, des motifs spatio-temporels particuliers, c'est-à-dire, des séquences d'activité particulières au travers des différents neurones. Pour cela, l'objectif était que le réseau apprenne les délais de conduction nécessaires à ce que les neurones d'entrée, composant le motif spatio-temporel, ainsi que les neurones de sortie, détectant son occurrence, s'organisent en groupes polychrones. Il a donc dans un premier temps fallu générer artificiellement des raster plots reproduisant une certaine activité neuronale, comportant un motif spatio-temporel à détecter dans un environnement bruité. Puis, il a fallu modéliser les neurones de sorties du réseau pour qu'ils émettent un potentiel d'action au moment où le motif d'intérêt est détecté. Enfin, il a fallu établir une règle d'apprentissage permettant aux poids et aux délais du réseaux de s'organiser de manière optimale à la détection des séquences d'intérêt.

Etat de l'art

NADAFIAN

TEMPOTRON

II. Méthode

Comme énoncé en introduction, l'objectif du réseau est de détecter, dans une matrice d'activité générée artificiellement, l'occurrence d'un motif spatio-temporel structuré en intégrant, à chaque étape du traitement de l'information, une dimension temporelle. L'activité d'entrée modélisera ainsi l'encodage temporel d'une information. La construction du réseau et la modélisation des neurones de sortie sera réalisée de manière à modéliser la temporalité de la transmission et de l'intégration de l'information : la temporalité de la transmission sera assurée par l'implémentation de délais de conduction alors que la temporalité de l'intégration de l'information sera assurée par la modélisation de neurones impulsionnels permettant la sommation temporelle des activités évoquées. Les règles d'apprentissages permettront de moduler les délais de conduction et ainsi, d'influencer la transmission et l'intégration de l'information. Cette plasticité des délais de conduction permettra alors au réseau de s'organiser en groupes polychrones pour détecter l'occurrence des motifs.

Génération de l'activité – motif structuré dans du bruit

Pour générer artificiellement l'activité neuronale d'entrée de notre réseau, nous avons utilisé la librairie python Numpy. L'objectif est de générer une matrice d'activité comprenant un motif spatio-temporel structuré dans un environnement bruité.

Génération du motif spatio-temporel

Pour générer ce qui pourrait s'apparenter à l'encodage temporel d'une information, nous avons défini plusieurs fonctions nous permettant de générer différents types de motifs tel que :

la fonction cosinus, permettant de modéliser une courbe représentative d'une fonction périodique :

Commenté [CB4]: Est ce que ces motifs sont particulièrement intéressant pour modéliser l'activité neuronale ? Si oui, pourquoi ?

$$T \cdot \cos \cdot f \left(\frac{i}{N} \right)$$


la fonction de von Mises, permettant de modéliser une courbe représentative d'une distribution normale circulaire:

Tapez une équation ici. $T \cdot \exp \left(\kappa \cdot \cos \left(2 \cdot \pi \cdot \frac{i}{N} \right) \right)$

la fonction linéaire, permettant de modéliser une droite :

Tapez une équation ici. $T \cdot \frac{i}{N}$

De cette manière, nous pouvons générer différents types de motifs structurés, sur l'ensemble des neurones d'entrée.



Génération de l'activité de bruit


Le terme d'activité de bruit est utilisé pour désigner dans un enregistrement neuronal, les signaux aléatoires, non désirés et ne portant à priori, aucune information. L'activité de bruit sera alors générée de façon à modéliser ce caractère hasardeux/aléatoire du bruit. Pour cela les adresses et les temps d'occurrence des potentiels d'action seront tirés selon une loi de distribution uniforme. La proportion de bruit (*noise*) sera estimée à partir de la densité de

bruit désirée (d), du temps de simulation (t_{sim}) ainsi que du nombre de neurones d'entrée (n) tel que :


$$noise = d \cdot t_{sim} \cdot n$$

Où d à été fixé en se basant sur....

Commenté [CB5]: Sur quoi on s'est basé pour déterminer la densité de bruit et le temps de simulation ?



Ainsi, nous disposons d'une matrice d'activité comprenant un ou plusieurs motifs spatio-temporels, ainsi qu'une matrice d'activité comprenant l'activité de bruit. A elles deux, ces matrices représenteront notre activité d'entrée.



Il est à noter que pour faciliter et accélérer les calculs ultérieurs, nous générons notre activité de façon événementielle : le temps de simulation n'est pas discrétisé, les potentiels d'actions sont assignés à des coordonnées temporels précis, de l'ordre de la machine, et non à une fenêtre temporelle tel que :

$$e_{in} = \left\{ (a_k, t_k), \quad k = \{1 \dots n_{spike}\} \right\}$$

Où e_{in} représente l'activité d'entrée, modèle de l'encodage temporel d'une information, k les potentiels d'action, a_k l'adresse de chacun d'entre eux et t_k le moment de leur occurrence.

Etant donné que seul le moment d'émission des potentiels d'action composant les motifs permette de différencier les différentes activités d'entrée -le nombre de potentiel d'action, lui, ne le permettant pas-, ce modèle d'activité est concordant à la modélisation d'un encodage temporel de l'information.

Modélisation des neurones de sortie – **delayed Leaky Integrate and Fire neurons (LIF)**

Commenté [CB6]: Parler des w + en détail

Après avoir généré l'activité des neurones d'entrée, il a fallu modéliser celle des neurones de sortie. Leur rôle est de s'organiser en groupe polychrone avec les neurones d'entrée composant un motif spatio-temporel et ainsi, d'émettre un potentiel d'action au moment de l'occurrence du motif. Conformément au raisonnement sous-tendant le sujet de mon stage et à la définition des groupes polychrones, cette détection se fera aux moyens d'une transmission et d'une intégration de l'information incluant une dimension temporelle, toutes deux respectivement assurée par l'implémentation de délais de conduction et par la sommation temporelle des activités évoquées dans les neurones de sortie.

Modélisation de la transmission de l'information

Les neurones de sorties (n_{out}) seront alors modélisés par leur matrice de connexion, caractérisée par des forces et des délais de conduction tel que :

$$n_{out} = \{ w, d_a \}$$

Où w et d correspondent respectivement aux poids et délais de conduction synaptiques des a connexions.

Ainsi, l'activité d'entrée, transposée au niveau du soma des neurones de sortie, pourrait alors être exprimée tel que :

$$e_{soma} = \left\{ (a_k, t_k + d_{a_k}), \quad k = \{1 \dots k_{spike}\} \right\}$$

Modélisation de l'intégration de l'information

Le potentiel de membrane des neurones de sortie sera fixé par le modèle *Leaky Integrate and Fire (LIF)*, développé par Louis Lapicque en 1907^{vii}. Dans ce modèle, le neurone est représenté comme un circuit électrique dont le voltage représente le potentiel de membrane du neurone. Ce dernier dépend d'une capacitance et d'une résistance aux courants de fuites, tous deux responsables de la repolarisation de la membrane après une dépolarisation. Après l'injection d'un courant positif dans le circuit, le voltage augmente puis, en raison des courants de fuite, diminue de façon exponentielle selon la constante de temps τ . Si l'amplitude de la dépolarisation permet au voltage de dépasser un certain seuil, alors le neurone émettra un potentiel d'action avant que le potentiel de membrane ne retrouve sa valeur de repos.


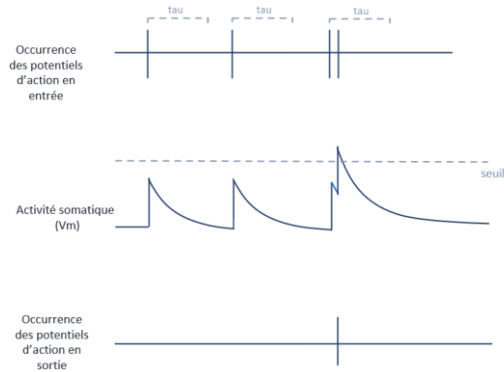


FIG. 1. The integrate-and-fire model of Lapicque. (A) The equivalent circuit with membrane capacitance C and membrane resistance R . V is the membrane potential, V_{rest} is the resting membrane potential, and I is an injected current. (B) The voltage trajectory of the model. When V reaches a threshold value, an action potential is generated and V is reset to a subthreshold value. (C) An integrate-and-fire model neuron driven by a time varying current. The upper trace is the membrane potential and the bottom trace is the input current.

L'intérêt de ce modèle est la temporalité de l'intégration, implémentée par la constante τ . Cette dernière définit la dynamique de repolarisation du potentiel après dépolarisation. Cette décroissance progressive permet la sommation des activités évoquées par des potentiels d'actions dont l'occurrence serait comprise dans cette fenêtre temporelle.



Cette temporalité s'accorde bien avec l'idée du fonctionnement de notre réseau : pour s'organiser en groupes polychrones avec les neurones impliqués dans une séquence d'intérêt, les neurones de sortie devront apprendre, au cours de l'apprentissage, des délais de conduction permettant aux potentiels d'action composant cette séquence de rejoindre le soma de façon synchronisée. Cette synchronie permettra la sommation des activités évoquées et donc l'émission d'un potentiel d'action, signalant son occurrence.

L'idée serait alors de modéliser la dynamique du potentiel de membrane des neurones de sortie selon ce modèle LIF. L'amplitude des activités évoquée par l'occurrence d'un potentiel d'action pré-synaptique sera déterminée par le poids de la connexion, et le moment de la dépolarisation modulée par le délai de conduction. Le seuil de voltage sera déterminé de sorte à favoriser l'émission de potentiels d'action pour des activités synchrones.

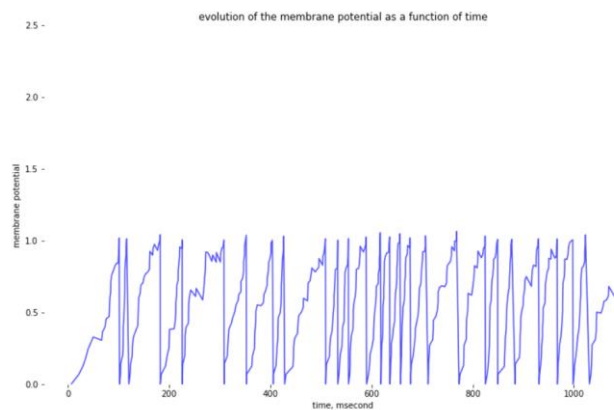
Le potentiel de membrane au moment de l'occurrence d'un potentiel d'action pré-synaptique s'exprimera alors tel que :

$$V_k = e^{\left(\frac{-dt}{\tau}\right)} \cdot (V_{k-1} + w)$$

Où V_{k-1} représente la valeur du potentiel de membrane avant l'occurrence du potentiel d'action, où w représente le poids synaptique, et donc l'amplitude de la dépolarisation, où τ représente la temporalité de repolarisation du neurone, fixé _____ et où dt représente la différence de temps entre les potentiels d'action rejoignant le soma tel que :

$$dt = \{ t_k + d_{a_k} - (t_{k-1} + d_{a_{k-1}}) \}$$

Il est intéressant de souligner le fait que, grâce à la représentation événementielle de l'activité, le calcul de V ne se fait pas sur des fenêtres temporelles discrétisées mais en fonction de l'occurrence de chaque potentiel d'action.



Modélisation de la détection du motif


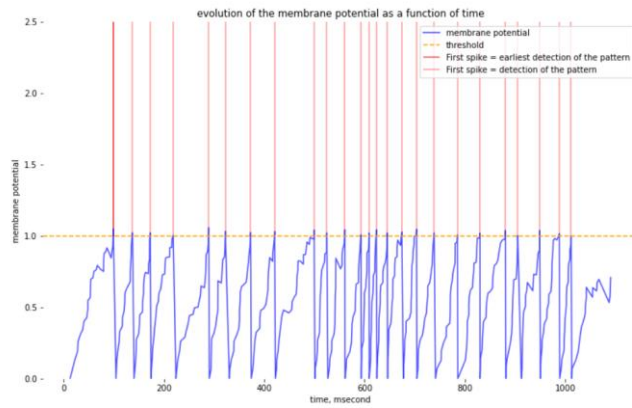
L'émission d'un potentiel d'action par les neurones de sorties et donc, la détection du motif d'intérêt, sera déterminée par le franchissement d'un seuil de voltage. Nous ne prendrons en considération que le premier potentiel d'action émit par le neurone de sortie tel que :

$$t_{out} = \operatorname{argmax}(V > \text{seuil})$$

Où t_{out} représente le moment auquel le neurone de sortie émet le premier potentiel d'action et donc, le moment où le motif est détecté et où le **seuil** a été déterminé tel que

Commenté [CB7]: Justifier la valeur de tau

Commenté [CB8]: Justifier la valeur du seuil




Règle d'apprentissage : STDP supervisée

Une fois que l'architecture de notre réseau a été construite, il a fallu déterminer une règle d'apprentissage des poids et des délais pour permettre au réseau de s'organiser en groupes polychrones. Nous avons pour cela testé différentes stratégies.

Apprentissage supervisé pour la détection d'un seul motif spatio-temporel

Étant donné que nous avons généré nos données artificiellement, nous connaissons le moment précis de l'occurrence des motifs spatio-temporels. Cela nous permet de recourir à un apprentissage supervisé. Nous avons opté pour la règle d'apprentissage Hebbien dépendant du moment d'occurrence des potentiels d'action pré et post-synaptique : la *Spike Timing Dependant Plasticity (STDP)*. Cette règle repose sur le principe selon lequel les neurones qui déchargent ensemble renforcent leur lien, alors que ceux qui déchargent de façon désynchronisée le perde. Si un neurone pré-synaptique émet un potentiel d'action avant un neurone post-synaptique, alors leur lien sera renforcé ; à l'inverse, si un neurone pré-synaptique émet un potentiel d'action après un neurone post-synaptique, leur lien sera atténué. Plus la différence entre les temps d'émission pré et post-synaptique est proche de 0, plus la modulation de leur lien sera importante.



Nous utiliserons ce principe de modulation synaptique en fonction du moment d'occurrence des potentiels d'action pour l'apprentissage des poids et des délais.

STDP supervisée pour l'apprentissage des poids

Les poids, ou forces de connexion synaptiques, permettent de moduler l'amplitude des réponses évoquées par l'occurrence d'un potentiel d'action. L'apprentissage des poids permettra donc d'ajuster cette amplitude pour que les activités évoquées par un seul potentiel d'action ne permettent pas le franchissement du seuil de voltage, mais que seule la sommation des activités évoquées le permette. Nous définirons donc un poids global, pour toutes les connexions d'un neurone de sortie, permettant ainsi de déterminer une certaine homéostasie dans le réseau.

La modulation des poids à chaque époque se fait tel que :

$$w_{epoch} = w_{epoch-1} + \Delta w$$

Où Δw représente l'amplitude de la modulation des poids tel que :


$$\Delta w = \Delta w_0 * \tanh -\frac{t_{err}}{\tau}$$

Où w_0 est le coefficient de _____ et où t_{err} assure la supervision de la STDP tel que :

Commenté [CB9]: Comment dire.....

$$t_{err} = t_{true} - t_{out}$$

t_{true} étant le moment d'occurrence du motif, et t_{out} étant le moment auquel le neurone de sortie à émit son premier spike, soit le moment auquel la séquence à été détectée.



Si $t_{true} < t_{out}$ alors $t_{err} < 0$ et $\Delta w > 0$.

Les poids du réseau seront alors augmentés pour faciliter l'émission d'un potentiel d'action plus rapidement.

A l'inverse, si :

$t_{true} > t_{out}$ alors $t_{err} > 0$ et $\Delta w < 0$.

Les poids de connexion du réseau seront alors diminués pour retarder l'émission d'un potentiel d'action.

On retrouve dans le système nerveux des mécanismes homéostasiques similaires tels que ...

Commenté [CB10]: À expliciter

STDP supervisée pour l'apprentissage des délais

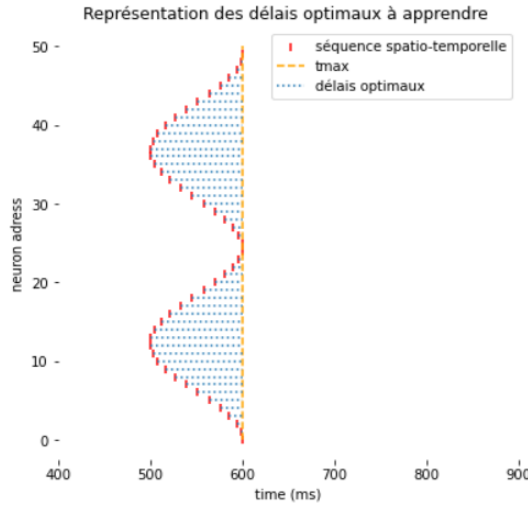
L'apprentissage des délais a pour objectif de permettre aux potentiels d'actions composant un motif spatio-temporel, de rejoindre le soma des neurones de sortie de façon synchronisée et ainsi, de permettre au réseau de tendre vers une organisation en un groupe polychrone permettant la détection correcte du motif-spatio-temporel. Plus précisément, les délais de conduction devraient permettre aux potentiels d'action composant la séquence de se synchroniser avec le dernier potentiel d'action de la séquence. Ainsi, on pourrait exprimer les délais optimaux à apprendre tel que :

$$d_{true} = t_{max} - t_{seq}$$

Où t_{max} correspond au moment d'occurrence du dernier potentiel d'action de la séquence et t_{seq} au moment d'occurrence des potentiels d'action composant la séquence.

Ainsi :

$$t_{seq} = t_{max} - d_{true}$$




Au début de l'apprentissage, les délais sont tirés aléatoirement selon une loi de distribution normale. Au cours de l'apprentissage les délais seront modulés tel que :

$$d_{epoch} = d_{epoch-1} + \Delta d$$

Où Δd représente l'amplitude de la modulation effectuée et est déterminé tel que :

$$\Delta d = \Delta d_0 \cdot \tanh \frac{\Delta t_{err}}{\tau} \cdot e^{-\frac{|\Delta t_{err}|}{\tau}}$$

Δd dépend alors de la variable Δt_{err} , assurant la supervision de la règle d'apprentissage. Δt_{err} correspond à la différence entre le temps d'occurrence du potentiel d'action en entrée qui, en prenant en compte les délais de conduction appris, se synchroniserait avec t_{max} , et le temps d'occurrence du potentiel d'action composant la séquence, c'est à dire le temps du potentiel d'action qui doit se synchroniser avec t_{max} . La différence de temps entre les deux déterminera alors l'erreur de délais apprise.



On peut exprimer Δt_{err} tel que :

$$\Delta t_{err} = (t_{max} - d_a) - t_{seq}$$


à l'équilibre :

$$d_a = d_{true} \quad \text{alors} \quad t_{max} - d_a = t_{seq} \quad \text{et} \quad \Delta t_{err} = 0 \quad \Delta d_a = 0$$

Au cours de l'apprentissage, si :

$$d_a < d_{true} \quad \text{alors} \quad t_{max} - d_a < t_{seq} \quad \text{et} \quad \Delta t_{err} < 0 \quad \Delta d_a < 0$$

$d_a > d_{true}$ alors $t_{max} - d_a > t_{seq}$ et $\Delta t_{err} > 0$ $\Delta d_a > 0$



Ainsi, nous disposons de deux règles d'apprentissage supervisées dépendant du moment d'occurrence des potentiels d'action : l'une pour l'apprentissage des délais, l'autre pour l'apprentissage des poids. A chaque époque, ces deux paramètres seront mis à jour de sorte à permettre une bonne détection des séquences

Apprentissage supervisé pour la détection de plusieurs motifs spatio-temporels

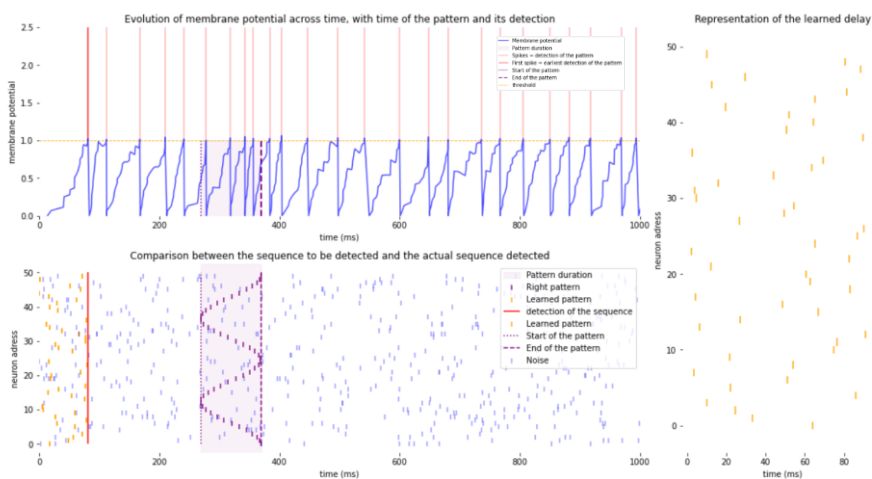
Apprentissage non supervisé pour la détection d'un motif spatio-temporel

III. Résultats

Expérience 1 : apprentissage supervisé d'un motif unique

Lors de cette expérience, nous présentons au réseau une succession de matrices d'activités, composées d'un unique motif spatio-temporel cos dans un environnement bruité. Pour chaque matrice d'activité présentée, l'occurrence du pattern se produit à un moment différent de la simulation. Le réseau est composé de 50 neurones d'entrées et de 1 neurone de sortie dont le rôle est d'émettre un potentiel d'action au moment de l'occurrence du motif spatio-temporel.

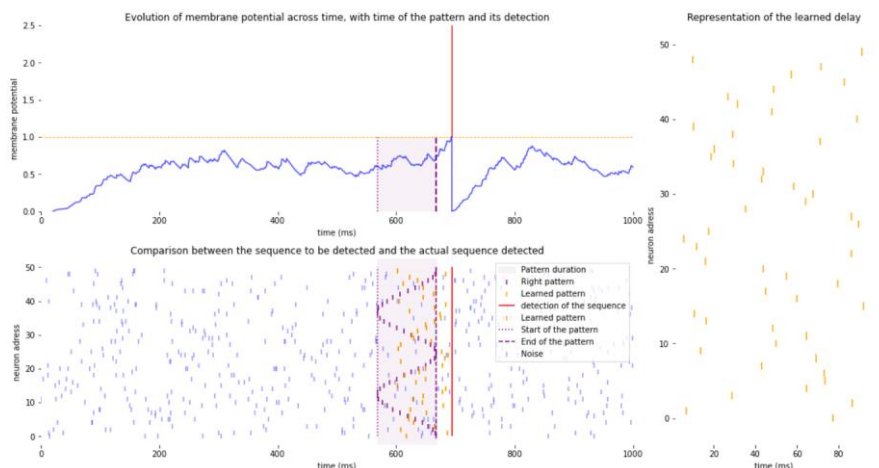
Au début de l'apprentissage :



Le neurone de sortie est initialisé avec des délais de conduction aléatoires (C). Lorsque l'on prête attention à l'évolution du potentiel de membrane du neurone de sortie au cours du temps (A), on remarque qu'il émet des potentiels d'action à différents moments de la simulation et ne détecte pas l'occurrence du motif, tous deux respectivement représentés par les barres verticales rouges et violettes. L'objectif est que la détection du motif se synchronise avec le dernier potentiel d'action du motif.

La séquence de potentiels d'action synchronisés avec l'émission du premier potentiel d'action en sortie est représentée par les événements oranges (B). L'objectif est que ces événements se superposent avec les événements composant le motif. Cela signifierait que ces derniers arriveraient tous de façon synchronisée au niveau du soma du neurone de sortie. Les poids de connections étant initialement fixés à 0.1 et le seuil à 1, dès qu'une séquence de potentiel d'action dans l'activité de bruit permet, en prenant en compte les délais de conduction aléatoires, la sommation de suffisamment d'activité évoquée dans la fenêtre temporelle τ pour que le potentiel de membrane ne franchisse le seuil de voltage, le neurone de sortie émet un potentiel d'action.

Au cours de l'apprentissage :

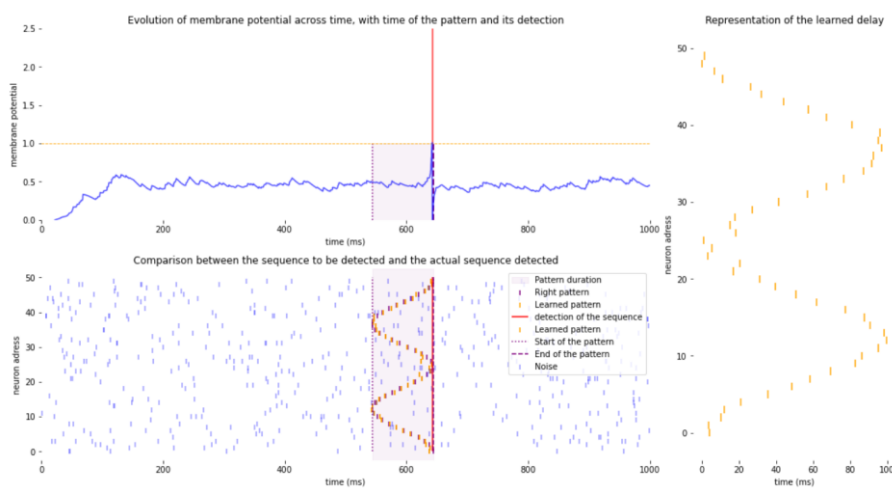


Les poids et délais sont progressivement ajustés, de sorte à ce qu'ils permettent la sommation temporelle de tous les potentiels d'action composant le motif d'intérêt au niveau du neurone de sortie et donc, sa détection.

On remarque, en C que les délais appris commencent à présenter une certaine structure. En A, on remarque que le neurone de sortie n'émet plus qu'un potentiel d'action, un peu après l'occurrence du motif.

L'activité de bruit, de par son caractère aléatoire, ne présente aucune. Ainsi, avec les délais appris, l'activité de bruit ne permet plus la sommation des activités évoquées et ainsi le franchissement du seuil de voltage. Cependant, les délais et poids appris ne permettent pas encore la détection correcte du motif et le neurone de sortie émet un potentiel d'action à un moment ne correspondant pas à l'occurrence exacte du motif (A et B).

Après apprentissage :



Les délais de conduction appris reflètent désormais le motif d'intérêt (C). Ainsi, en prenant en compte les délais de conduction appris, la séquence spatio-temporelle permettant la sommation temporelle des activités évoquées, et donc, l'occurrence d'un potentiel d'action en sortie, se superpose parfaitement avec la séquence du motif (B). Le neurone de sortie émet un potentiel d'action synchronisé sur l'occurrence du dernier potentiel d'action composant le motif (A). L'apprentissage des délais et des poids ont ainsi permis au réseau de s'organiser en un groupe polychrone permettant de détecter correctement, et avec précision, le motif spatio-temporel dans la matrice d'activité.

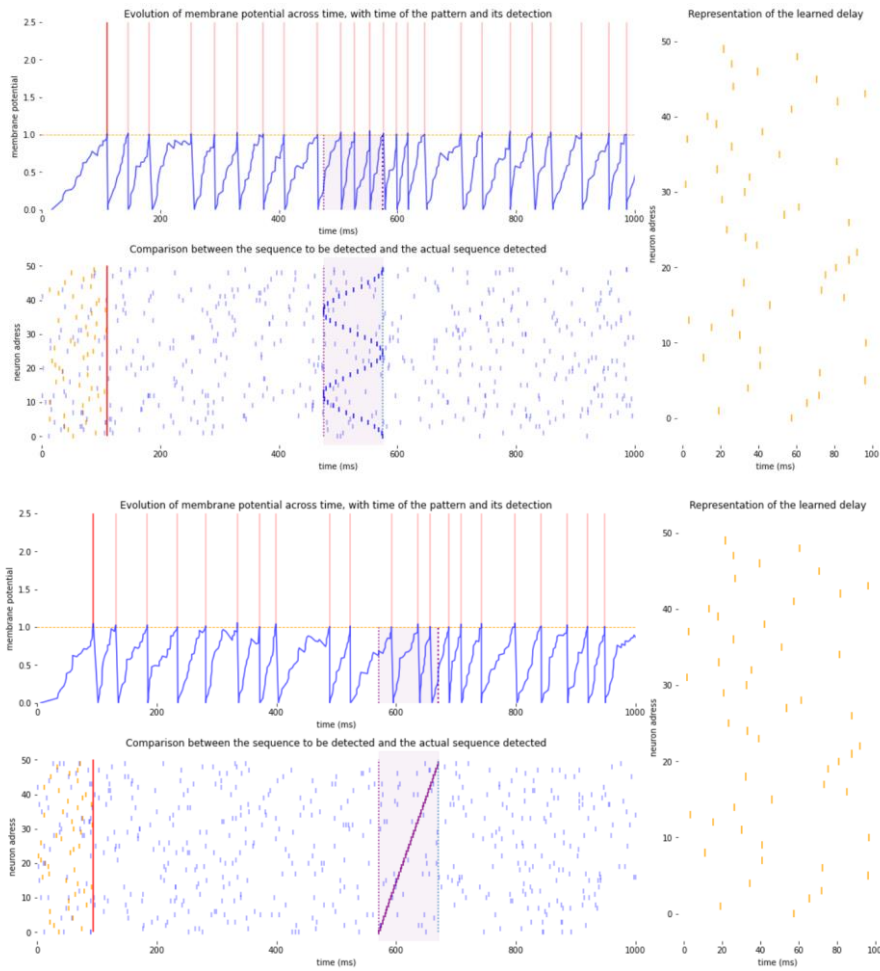
Ainsi, la temporalité implémentée dans la transmission de l'information, dans l'intégration de l'information et dans l'apprentissage ont permis de détecter l'occurrence d'une séquence d'activité pouvant s'apparenter à un encodage temporel.


Expérience 2 : apprentissage supervisé de plusieurs motifs

Dans cette expérience, le réseau est cette fois composé de 50 neurones d'entrée et 3 neurones de sortie. L'objectif est de tester si l'architecture fonctionnelle du réseau permet de détecter et différencier l'occurrence de trois motifs spatio-temporels différents dans un environnement bruité. Ainsi, on présente à chaque époque, trois matrices d'activité successives, chacune composée d'un motif spatio-temporel différent dans un environnement bruité : un motif cos, un motif linéaire et un motif vonmises. Chaque neurone de sortie est chargé de détecter l'occurrence d'un de ces motifs.

Au début de l'apprentissage :

Les trois neurones sont initialisés avec des délais de conduction aléatoire et un poids synaptique de 0.1. Les neurones de sortie émettent des potentiels d'action à différents moments de la simulation (A) et ne détectent aucun des trois motifs(B).

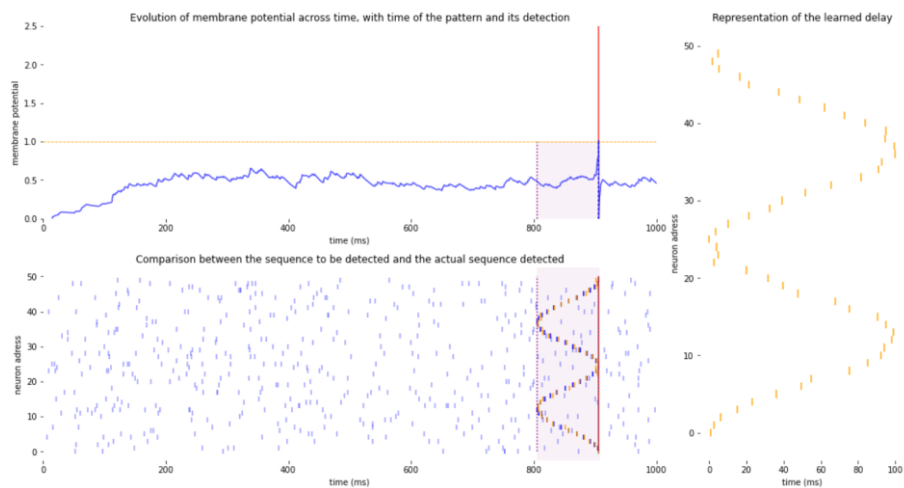





Après apprentissage :


Les neurones parviennent à apprendre, les délais de conduction permettant aux potentiels d'action composant le motif qu'ils devaient détecter d'arriver de façon synchrone au niveau du soma du neurone de sortie, de manière synchronisée avec l'occurrence du dernier potentiel d'action du motif.

En effet, on voit en C et B que les délais appris par le neurone 1 permettent seulement aux activités évoquées par des potentiels d'action composant le motif cos, de se synchroniser avec le dernier potentiel du motif. Ainsi, on voit en A et B que lors de la présentation du motif cos, le 1 émet un potentiel d'action synchronisé avec le dernier potentiel d'action du motif.




Cependant, le potentiel de membrane de ce neurone ne franchit jamais le seuil de voltage suite à la présentation de matrices d'activités comprenant des motifs linéaires ou vonsmises.

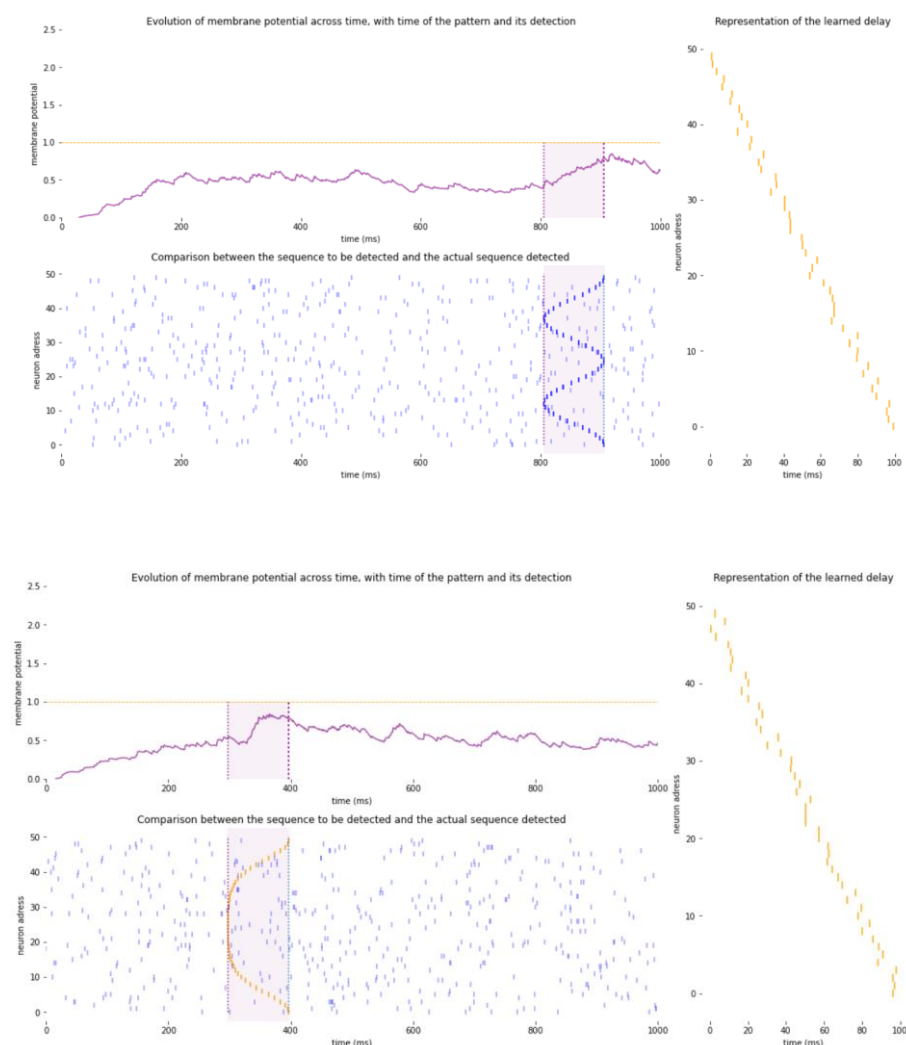




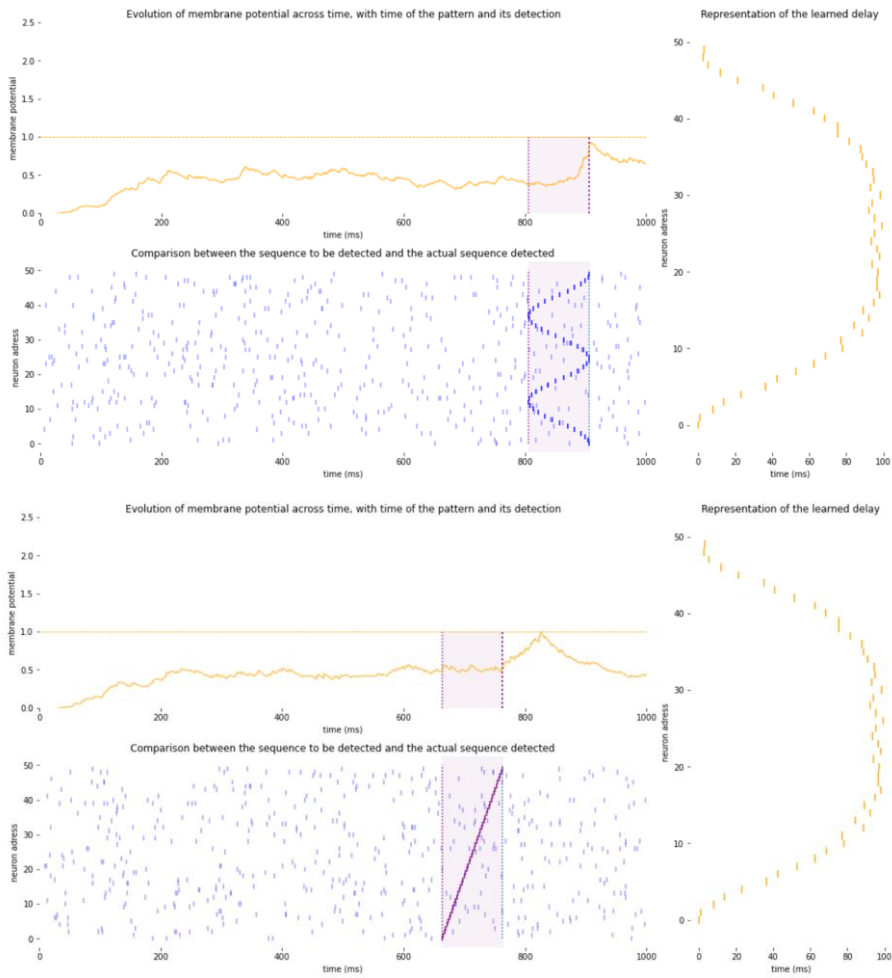
Il en est de même pour le neurone 2, chargé de la détection du motif linéaire. Les délais appris en C permettent aux potentiels d'action composant le motif linéaire de se synchroniser avec le dernier potentiel d'action du motif (B). Le neurone 2 émet donc un potentiel d'action synchronisé avec le dernier spike du motif (A et B).

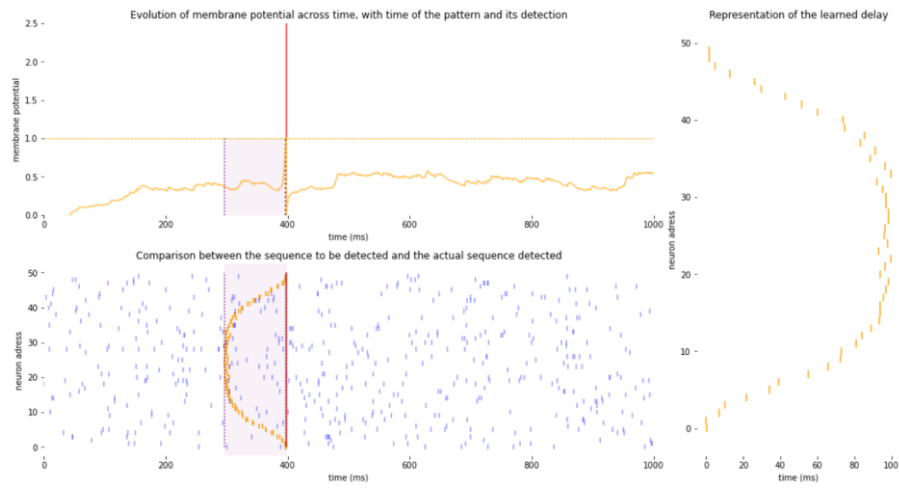


Suite à la présentation des autres motifs, la sommation des activités évoquées ne permet pas le franchissement du seuil (A) et B)



Neurone 3 :








Expérience 3 : apprentissage non-supervisé de plusieurs motifs

IV. Discussion & perspectives

- Résumé des contributions
- limites =
 - motifs avec un spike par neurone
 - non supervisé à explorer Cam's means
 - appliquer à des données plus complexes que synthétique:
 - event-based



https://laurentperrinet.github.io/grant/anr-anr/event_driven_computations.png A miniature, event-based ATIS sensor. Contrary to a classical frame-based camera for which a full dense image representation is given at discrete, regularly spaced timings, the event-based camera provides with events at the micro-second resolution. These are sparse as they represent luminance increments or decrements (ON and OFF events, respectively).

- data – transition toute trouvée:

- Perspectives : application à des données réelles

-
- ⁱ RESCORLA, Michael. The computational theory of mind. 2015.
- ⁱⁱ GOLLISCH, Tim et MEISTER, Markus. Rapid neural coding in the retina with relative spike latencies. *science*, 2008, vol. 319, no 5866, p. 1108-1111.
- ⁱⁱⁱ CELEBRINI, Simona, THORPE, Simon, TROTTER, Yves, *et al.* Dynamics of orientation coding in area V1 of the awake primate. *Visual neuroscience*, 1993, vol. 10, no 5, p. 811-825.
- ^{iv} ABELES, M., 1991, *Corticonics: Neural Circuits of the Cerebral Cortex*. Cambridge : Cambridge University Press.
- ^v PAUGAM-MOISY, Hélène et BOHTE, Sander M. Computing with spiking neuron networks. *Handbook of natural computing*, 2012, vol. 1, p. 1-47.
- ^{vi} IZHKEVICH, Eugene M. Polychronization: computation with spikes. *Neural computation*, 2006, vol. 18, no 2, p. 245-282.
- ^{vii} ABBOTT, Larry F. Lapique's introduction of the integrate-and-fire model neuron (1907). *Brain research bulletin*, 1999, vol. 50, no 5-6, p. 303-304.